

음성 인공지능의 고유명사 인식 성능 향상 연구

2018312181 서원렬

2022311970 이은제

2023316008 이민선

목차

1. 음성 인식 시장의 성장
2. ASR 모델 작동 원리 및 Whisper
3. ASR의 고유명사 인식 문제 및 Biasing List의 필요성
4. 핵심 기술 1: contextual prompting
5. 핵심 기술 2: Hotword Boosting
6. 성능 평가 척도: WER 및 CER
7. 실험 결과 및 분석
8. 분석 포인트

음성 인식 시장의 성장

AI 기술 발전과 스마트 기기 확산으로 음성 인식 시장은 매년 두 자릿수 성장 중입니다. 2024년 기준 수백억 달러 규모에서 향후 5~7년 내에 두 배 이상 성장하여 2030년경에는 1000억 달러에 육박할 것으로 전망됩니다.

주요 성장 동력

- 스마트 스피커
- 차량용 인포테인먼트
- 헬스케어
- 고객 서비스 자동화

ASR 모델 작동 원리 및 Whisper

1. ASR(Automatic Speech Recognition, 자동 음성인식) 모델 아키텍처

최신 ASR 모델은 음성 신호를 텍스트로 변환하기 위해 딥러닝 기법을 활용하며, 주로 다음 단계를 거칩니다.

- **음향 특징 추출:** 음성 파형에서 핵심 음향 특성 추출
- **인코더:** 추출된 음향 특징을 기반으로 음성 패턴 학습 및 고수준 표현 변환
- **디코더:** 인코더의 음성 표현을 바탕으로 텍스트 시퀀스 생성

2. Whisper 모델

Whisper는 OpenAI가 2022년 공개한 End-to-End 방식의 ASR 모델로, 강력한 음성 인식, 번역, 언어 감지 기능을 제공합니다.

- OpenAI 2022년 공개, Transformer 기반 Encoder-Decoder 구조 채택
- 68만 시간의 방대한 음성-텍스트 쌍 데이터로 훈련
- 이전 모델 대비 압도적인 데이터셋 규모로 강력한 일반화 성능 제공

ASR의 고유명사 인식 문제 및 **Biasing List**의 필요성

고유명사(Named Entity) 인식 문제

- **OOV(Out-Of-Vocabulary) 문제:** 모델이 학습하지 못한 새로운 고유명사는 인식하기 어렵습니다.
- **발음의 변칙성:** 고유명사는 표준화되지 않은 다양한 발음이 존재하고, 이를 인식하는 데 어려움이 있습니다. (예: Hyundai/현대/현다이, Samsung/삼성/삼송).

Biasing List의 필요성

- ASR 시스템은 일반적인 단어 인식에는 뛰어나지만, 고유명사 인식에 한계가 있습니다.
- Biasing List는 ASR 디코딩 과정에서 모델에 인식 정확도 향상을 위한 가이드라인(contextual biasing)을 줄 수 있고, 특정 단어(Hotword)에 가중치를 부여하여 해당 단어의 인식 확률을 명시적으로 높입니다.
- 이를 통해 발음이 유사한 단어 간의 혼동을 해결하고, 필수적인 고유명사 및 도메인 특화 용어의 인식률을 강제로 향상시킬 수 있습니다.

핵심 기술 1: Contextual Prompting

- **Contextual Prompting**이란: 모델에 대화 맥락, 예상 단어, 도메인 정보 등을 미리 제공합니다.
- **작동 방식:** 모델이 제시된 단어와 유사한 소리를 해당 단어로 인식하도록 유도합니다.
- **특성 :** 224개의 토큰(단어 혹은 문장)까지 인식 가능(일반적으로 100~150개 내외의 토큰 사용 시 좋은 효율성을 보인다고 알려짐)
- **사용법 :**

prompt="[AI", "딥러닝", "트랜스포머", "파이썬", "안녕하세요? 오늘은 기술 세미나입니다", "반갑습니다"] 결과: "아, 앞에서 전문 용어를 썼고 마침표를 안 썼구나!"라고 판단하여 비슷한 스타일로 전사를 합니다

- **주요 이점:**
 - OOV 문제 해결
 - 신조어 인식 개선
 - 도메인 특화 용어 인식 향상

핵심 기술 2: Hotword Boosting

- **Hotword Boosting이란:** 특정 단어의 가중치를 높여 인식 확률을 증가시키는 기술입니다.
- **작동방식:** 일반적인 음성 인식 모델은 확률에 기반합니다. 예를 들어 "아이패드"와 "아이패스"는 소리가 비슷하여 모델이 혼동할 수 있습니다. 이 때 "아이패드"를 Hot word로 등록하면, 모델이 비슷한 발음을 들었을 때 확률적으로 "아이패드"를 선택하도록 편향(Bias)을 줍니다.
- **주요 이점:**
 - 발음이 유사한 단어 간의 혼동을 해결하고,
 - 모델이 사전에 등록된 핫워드를 우선적으로 선택하도록 유도합니다.
- **Faster-Whisper 활용:**
 - Hotword Boosting 기능을 위한 파라미터를 공식 지원하며,
 - Whisper 모델을 빠르고 효율적으로 실행합니다.
- **예시**

```
hotwords= ["넷플릭스", "이 사랑도 통역이 되나요", "디즈니플러스", "만달로리안", "유튜브",  
"침착맨", "삼국지", "티빙", "환승연애", "애플티비플러스",  
"파친코", "왓챠", "해리포터와 마법사의 돌", "아이유", "임영웅"]
```

성능 평가 척도: WER 및 CER

WER (Word Error Rate)

어절 단위 오차율로, 전체 문장 인식 성능을 평가합니다.

$WER = (\text{틀린 어절의 개수}) / (\text{전체 어절의 개수})$

ex)

정답 텍스트 : 나는 당신을 사랑합니다

음성인식된 텍스트 : 나는 다싱을 사랑합니다

총 3개의 어절에서 1개의 어절이 틀렸으므로 $WER = 1/3 = 0.33$

CER (Character Error Rate)

음절(문자) 단위 오차율로, 정밀한 인식 성능을 측정합니다.

$CER = (\text{틀린 음절의 개수}) / (\text{전체 음절의 개수})$

한국어는 교착어 특성상 **CER** 평가가 더 적합합니다.

ex)

정답 텍스트 : 나는 당신을 사랑합니다

음성인식된 텍스트 : 나는 다싱을 사랑합니다

총 10개의 어절에서 2개의 어절이 틀렸으므로 $CER = 2/10 = 0.2$

실험 결과 및 분석

실험 설계

1. 30개 5초 내외의 TV용 텍스트를 3명의 목소리로 총 90개의 음성파일 준비
2. Contextual prompting, hotwords 적용을 한 Faster-Whisper 모델 기반 음성 인식 후 Text-Normalization 수행.
3. 정답 텍스트와 음성인식된 텍스트간의 WER, CER 측정, 문장 속 고유명사에 대한 WER, CER 측정
4. 결과 정리

독립변인 설정

Hotword DB에서 0, 10, 20, 50, 100개 단어 무작위 선택하여 hotwords 개수에 따른 ASR 성능 측정

분석 포인트 및 과적합 주의


WER 및 CER 변화

Hotword 개수 증가에 따른 WER 및 CER 수치 변화를 측정합니다.

과적합 주의

너무 많은 Hotword는 일반 단어 오인식 위험이 있으므로, 최적의 Hotword 개수를 도출해야 합니다.

실험 결과: WER 및 CER 성능 비교



Hotword 개수 증가에 따라 WER과 CER이 점진적으로 감소하는 경향을 보였습니다. 특히 Hotword 50개 적용 시 가장 낮은 오차율을 기록하여 고유명사 인식 성능 향상에 기여했음을 알 수 있습니다.

하지만 Hotword 개수가 100개로 증가했을 때는 오히려 오차율이 소폭 상승하여 과적합의 가능성을 시사합니다. 이는 너무 많은 Hotword가 일반 단어의 오인식을 유발할 수 있음을 의미합니다. 따라서 최적의 Hotword 개수를 신중하게 도출하는 것이 중요합니다.

결론

주요 연구 결과

- Hotword Boosting과 Contextual Prompting의 효과 입증
- 최적의 Hotword 개수(30개)에서 최고 성능 달성
- 고유명사 CER이 0.174에서 0.107로 38% 개선

주요 기여

- ASR 모델의 고유명사 인식 성능 향상 방법 제시
- 실제 환경에서 적용 가능한 실용적 솔루션 제공
- 최적의 Hotword 개수 도출을 통한 과적합 방지

향후 연구

- 더 많은 도메인 데이터를 활용한 일반화 성능 검증
- 다양한 화자 및 음성 환경에서의 성능 평가
- 실시간 Hotword 업데이트 메커니즘 추가

감사합니다